


邵启豪

邮箱: shaoqihao24@mailsucas.ac.cn

学校: 中国科学院大学 | 专业: 网络空间安全 | 年级: 本科二年级

GitHub 主页: github.com/No17Seventeen

个人主页: No17Seventeen.github.io/qhshao17



研究兴趣

- 大语言模型智能体, Agent Memory, Tool-use Agent
- 不确定性估计, 模型校准, 可靠决策评估
- Benchmark 设计, 长程任务评估, 工程化实验系统

教育背景

大连市第二十四中

2021.09 – 2024.06

高中

中国科学院大学, 网络空间安全专业

2024.09 – 至今

本科

研究经历

Agent Memory Benchmark

2026.06 – 至今

Causal Ripple Effect in Agent Memory | 进行中的研究

- 系统调研 HorizonBench、STALE、PersonaMem-v2、LongMemEval 等前沿 benchmark, 梳理其数据构造、任务设定与评测盲区。
- 抽象并整理长期记忆评测的数据构造范式, 包括 state-first generation、old/new observation pair、pre-evolution hard negative 等。
- 参与设计 Agent Memory 评估框架, 覆盖偏好演化、过期记忆抑制、over-personalization、premise resistance 等场景。
- 整理多维评测指标体系, 包括 evolved-static gap、old-preference distractor rate、记忆场景适用性判断能力等。

工程实践

Qwen-vLLM 推理服务优化

2026.06 – 2026.07

2026 全国大学生计算机系统能力大赛 – 先导杯 | 队长

- 在比赛约束下基于 vLLM 构建 Qwen 推理优化分支, 聚焦长上下文 prefill、decode、KV cache、采样热路径和自定义算子开销。
- 使用 Hipprof 与运行 artifact 分析 attention 路径、TTFT、TPOT 和 throughput 瓶颈。
- 在官方 benchmark 中将 16–32K 吞吐提升 143%, 8–16K 吞吐提升 75%, 4–8K 吞吐提升 49%; 最终排名 57/346。

技术能力

编程语言

Python, C/C++, JavaScript

深度学习

PyTorch, Transformers, Hugging Face, vLLM

Agent / LLM

Prompt Engineering, Tool-use Agent, RAG, Memory Mechanism, LangChain

评估与实验

Benchmark 设计, 指标设计, 消融实验, 错误分析, 校准分析

工程工具

Git, Linux, Docker, Conda, LaTeX

数据处理

NumPy, Pandas, Matplotlib, JSON, SQLite

奖项荣誉

- 中国科学院大学优秀共青团员, 校级, 2025
- 本科生三等奖学金, 校级, 2025

个人介绍

我关注 LLM Agent 在长期记忆、多工具调用和动态环境中的可靠决策问题, 尤其是 agent 如何在记忆可能过期、信息冲突或工具结果不完整时表达和处理不确定性。目前希望围绕 uncertainty estimation、agent memory benchmark 和工程化评估系统开展研究。